Cross-modal Numerical Anchoring in VLMs

Uncertainty-modulated graded pull, digit-pixel causality, and a free-lunch mitigation

EMNLP 2026 Main · ARR May 25 target

논문 스타일 정리 발표 (2026-04-29)
자료 : references/project.md §0 + docs/insights/

헤드라인 클레임 (§1 Introduction)

한 줄로 요약하는 본 연구의 주장

Cross-modal numerical anchoring in VLMs is **uncertainty-modulated graded pull,** not categorical capture — and concentrates on a **digit-pixel cue** inside the anchor image.

Setup novelty

다른 어떤 연구도 stand-alone rendered-number 이미지를 cross-modal anchor 로 open numerical VQA 에 적용한 적이 없음 .

Graded vs. categorical

Phase A A1: 7 모델 전부 wrong-base direction-follow 가 correct-base 보다 +6.9–19.6 pp 큼 . paired adopt 는 2–6 %.

Cognitive science 정합

Mussweiler & Strack 의 selective accessibility — uncertainty 에 비례한 anchor pull 과 일치 .

현실 시나리오와 위험

사용자가 VLM 에 여러 이미지를 함께 보여주는 상황은 늘고 있다

현실 시나리오	앨범 정리 / 멀티 - 스크린샷 / 문서 복수 첨부 — VLM 에 여러 이미지를 동시 입력하는 빈도가 높아짐
위험	정답과 무관한 이미지가 답변에 영향을 준다면 ? 특히 * 숫자가 그려진 이미지 * 가 다른 질문의 수치 답변을 끌어당긴다면 ?
인지과학 prior	Tversky-Kahneman / Mussweiler-Strack: 사람도 무관한 숫자에 anchored 되며 , 효과는 불확실할수록 강함
LLM 선행 연구	Jones-Steinhardt 2022, Echterhoff EMNLP Findings 2024: 텍스트 anchor 주입 시 유사 효과 확인
VLM 공백	시각적 anchor (rendered digit image) 가 다른 이미지의 수치 질문에 미치는 영향은 미답

Related Work — novelty 매트릭스 (§2)

핵심 setup 은 직접 선행 없음, 가장 가까운 이웃들과 명확한 차별

Extension	가장 가까운 선행	Novelty 판정
Cross-modal numerical anchoring (core)	VLMBias (다른 setup); typographic attacks (다른 task)	**Genuinely novel**
"Stronger on wrong cases" 비대칭	LLM/VLM anchoring 어디에도 없음	**Genuinely novel — strongest hook**
Dataset 확장 (VQAv2 → TallyQA/ChartQA/MathVista)	N/A — 방법론 위생	Required, not novel
ViT vs Conv-encoder ablation	Typographic-attack mech (arXiv 2508.20570)	Novel angle, ablation 가능
Confidence-modulated anchoring (logit, §6)	Phase A binary; LLM 쪽 entropy 연구 일부	**Continuous proxy = novel projection**
Encoder-blind upper-half mitigation (§7)	Weng et al. EMNLP 2024 Main (causal mediation)	**Cross-architecture locus = novel**

Findings-tier 패턴 → Main-tier 로 끌어올린 4 가지 lever: attention mass · causal ablation · mid-stack mitigation · confidence proxy

4 조건 setup (§3 Problem Definition)

sample_instance 마다 4 conditions: b / a / m / d

b target_only	**a** + anchor	**m** + anchor_masked	**d** + neutral
두 번째 이미지 없음	디지트 한 글자가 그려진 anchor 이미지	anchor 이미지의 디지트 픽셀 영역만 inpaint 로 가림	디지트 없는 FLUX 생성 이미지
baseline (pred_b)	*manipulation (pred_a)*	*digit-pixel control (pred_m)*	*2-image distraction control (pred_d)*

(a − d) gap → anchoring vs. distraction 분리 · **(a − m) gap →** digit-pixel 인과 분리 · **(wrong-base − correct-base) →** uncertainty 변조 분리

Canonical metrics — M2 (§3)

docs/insights/M2-metric-definition-evidence.md

```
adopt_rate          = #(pa == anchor AND pb != anchor)  /  #(pb != anchor)

direction_follow    = #( (pb−gt)·(pa−gt) > 0  AND  pa != pb )  /  #(numeric pair AND
anchor present)

exact_match         = #(pa == gt)  /  #(numeric pair)

anchor_effect_M     = M(anchor arm) − M(neutral arm)
```

표기 통일

pred_b / pred_a / pred_m / pred_d = 각 condition 의 prediction

anchor = anchor image 의 value · **gt** = ground truth

Boolean flags: pb_eq_a / pa_eq_a / gt_eq_a / pa_ne_pb / pb_eq_gt

왜 이 조합 ?

- 18 변종 중 가장 깔끔 (M2 evidence)
- wrong > correct gap S0/S1 에서 22/22 보존
- distance decay S1 > S5 100%
- anchor > masked S0/S1 에서 5/6 보존

M2 — Adopt variant signal preservation

다양한 (numerator, denominator) 조합 비교

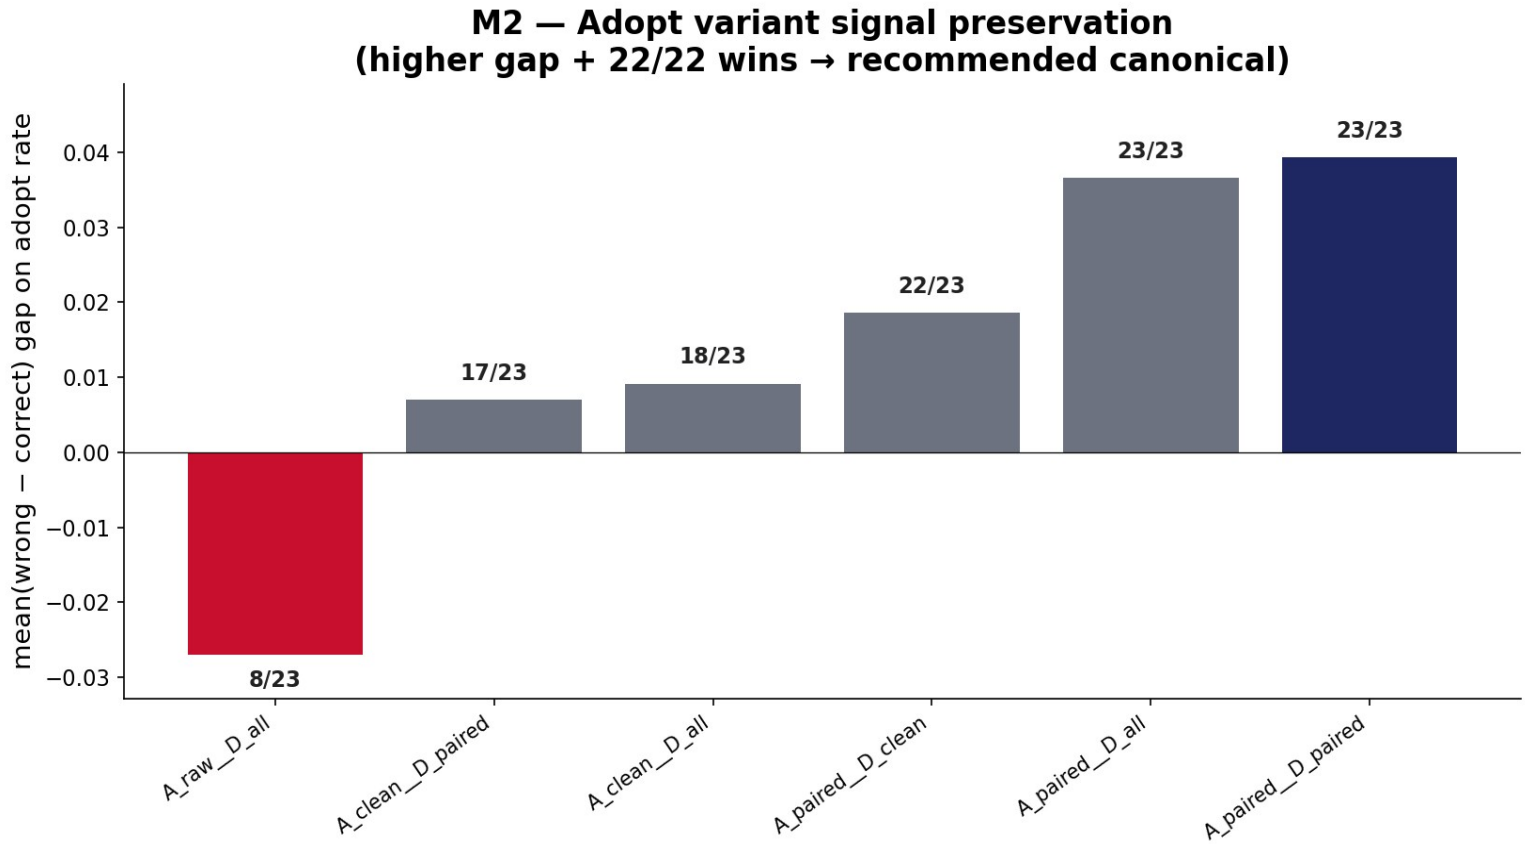

▷ **A_paired__D_paired**
paired numerator + paired denominator

→ wrong>correct gap +0.040, 22/22 cells

▷ **A_raw__D_all (pre-M1 marginal)**
→ gap −0.028 (wrong < correct, 8/22)

gt==anchor confound 이 신호 역전시킴

선택 : A_paired__D_paired (M2)

Datasets + Anchor Inventory (§4)

4 datasets · FLUX-rendered digit anchor + masked + neutral

Dataset	GT range	샘플	anchor selection rule	Status
VQAv2 number	0–8	17,730	anchor ∈ {0..9} (range-restricted)	[done] 7-model main + 7-model strengthen
TallyQA number	0–8	≈11,200	absolute |a−gt| ≤ 5 (S1)	[in flight] E5b 1-model + E5e 1/3 models
ChartQA	1–1000+	≈5,400	relative |a−gt| ≤ max(1, 0.10·gt)	[done] E5e 3 models
MathVista (integer)	1–1000	385	relative_s1 (same)	[done] gamma-alpha 3 models (2026-04-29)

Anchor 생성 파이프라인

(1) FLUX 로 480×480 anchor 이미지 생성 ({0..10000} 중 128 개) → **anchor**
(2) 동일 이미지에 OpenCV Telea inpaint 로 디지트 픽셀만 가림 →
masked
(3) FLUX 로 디지트 없는 자연 장면 이미지 별도 생성 →
neutral

Distance × Plausibility Window (E5b)

wrong-base 에서 anchor 거리가 가까울수록 adoption ↑

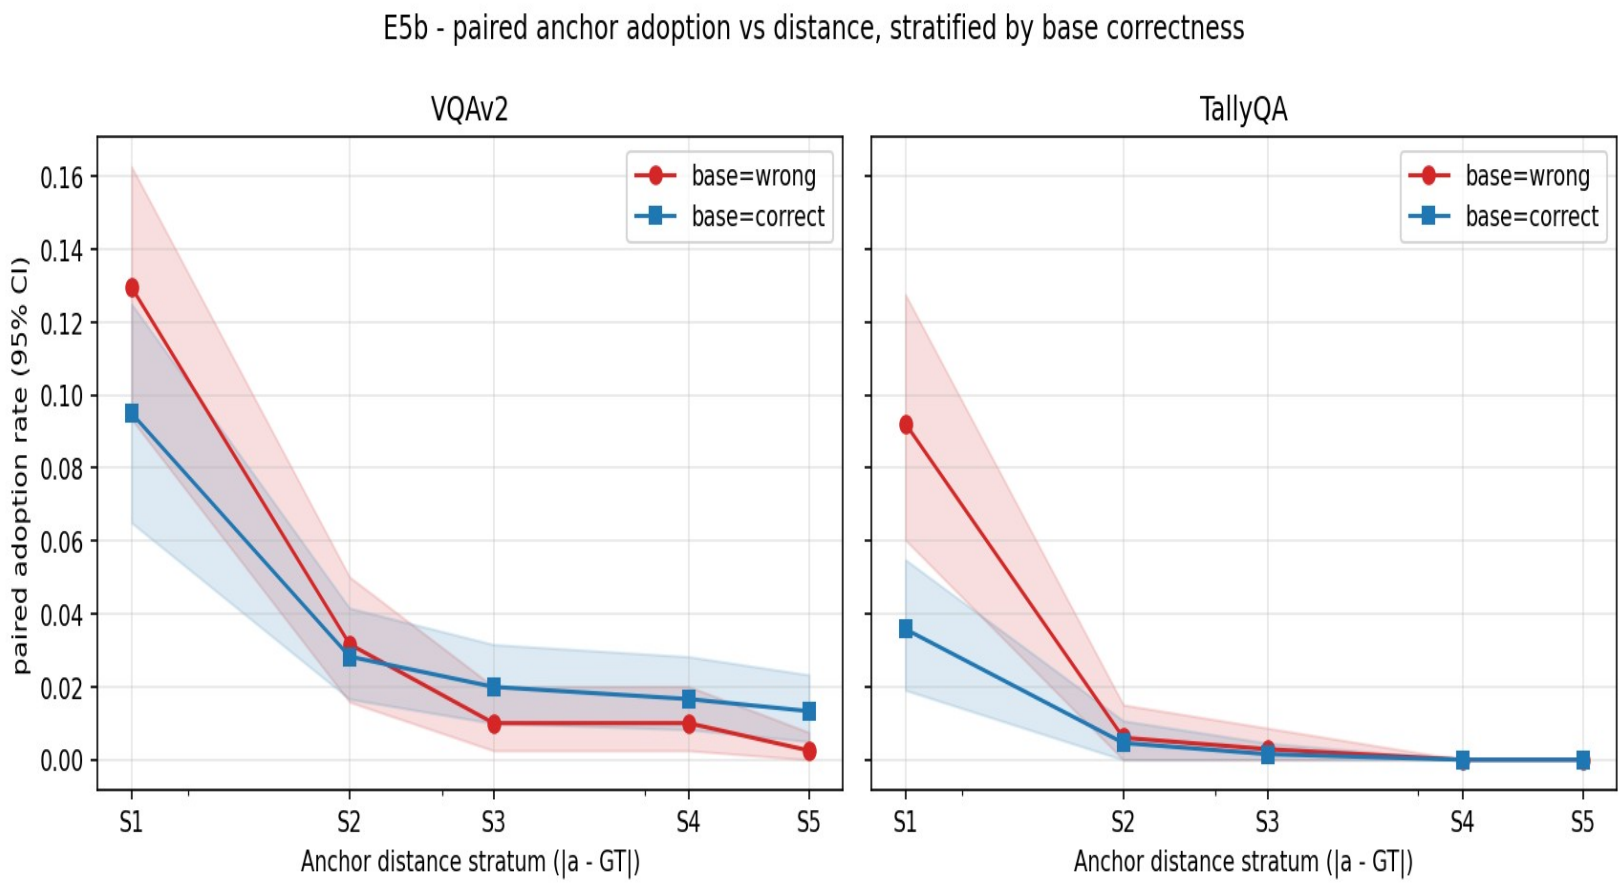

S1 [|a-gt| ≤ 1] 가장 큰 effect, S5 [301+] 에서 노이즈 floor

VQAv2 wrong-base S1 = **0.131**, S5 = 0.003 (44× 차이)

TallyQA wrong-base S1 = **0.092**, S5 = 0.000 (∞ 차이)

결론 : anchor 가 plausible 할 때만 effect 발생 .

Cross-dataset overlay (E5b)

VQAv2 / TallyQA wrong-base 만 같은 그래프에

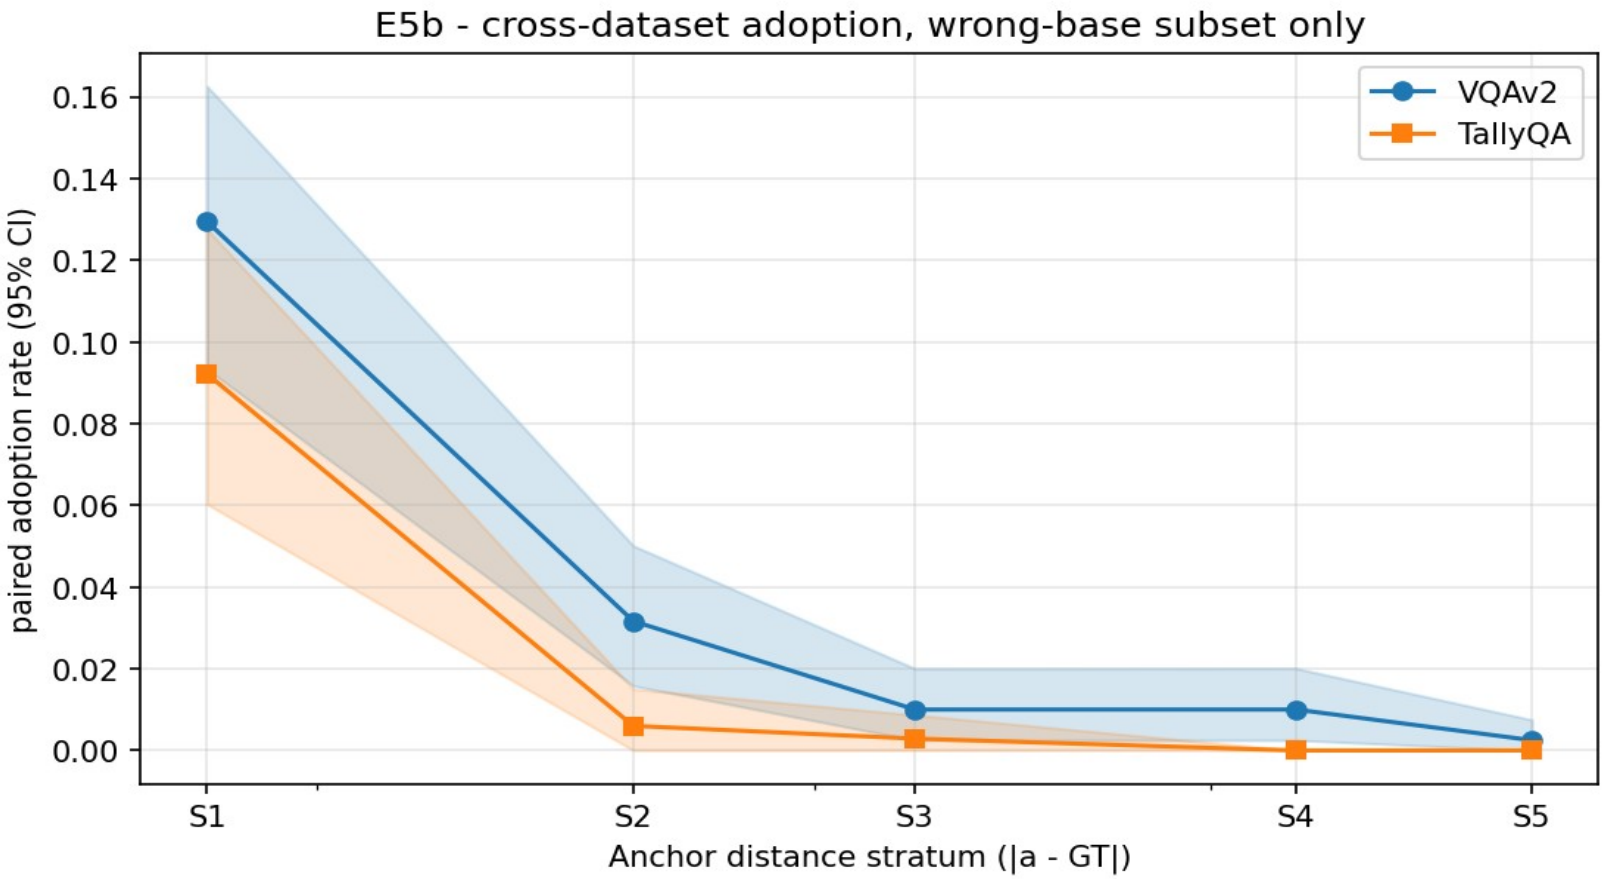

두 데이터셋의 baseline 정확도가 매우 다름 :

acc(b) VQAv2 0.62 vs TallyQA 0.21

그럼에도 **adopt 곡선의 모양은 동일** — image domain 에 의존하지 않는 효과 .

S1 → S5 단조 감소가 cross-dataset robust.

Digit-pixel causality (E5c)

anchor − masked gap → 디지트 픽셀이 effect 의 인과

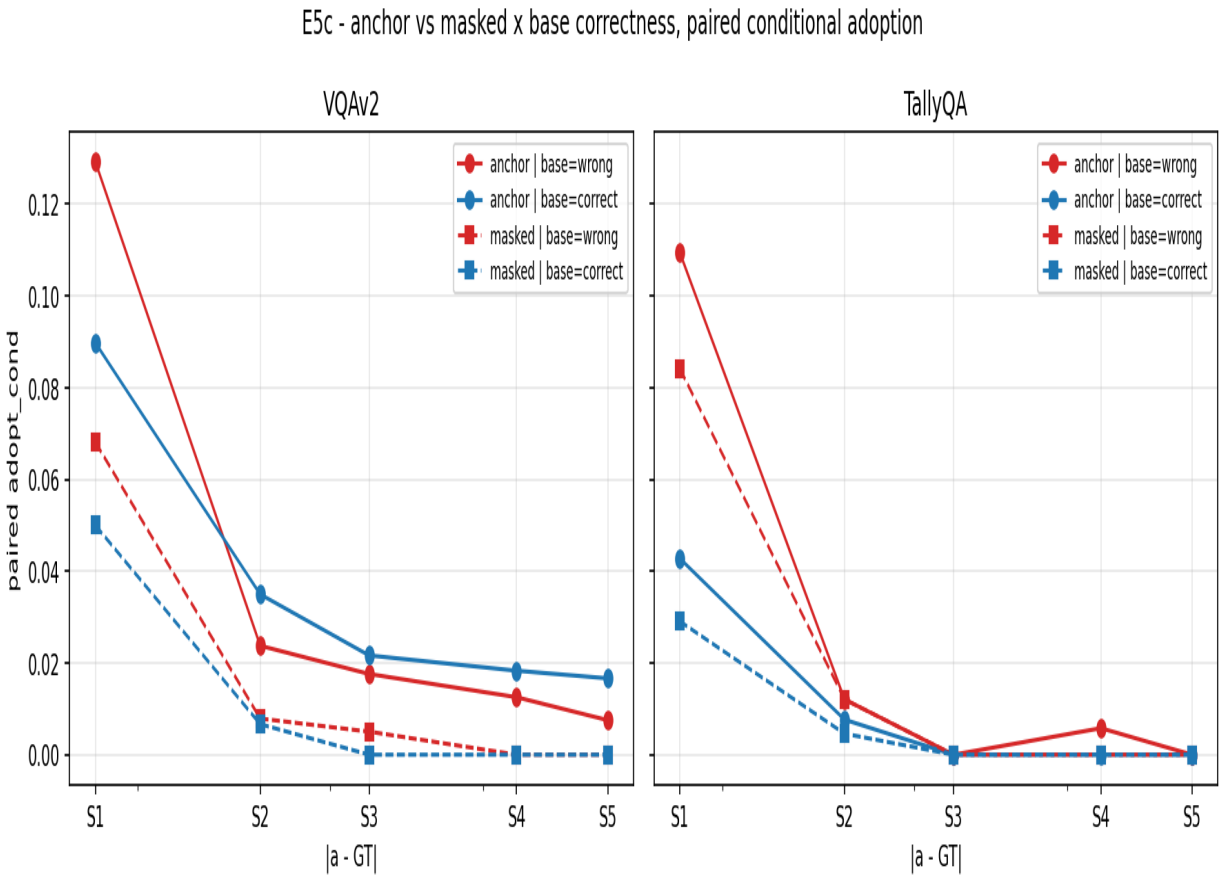

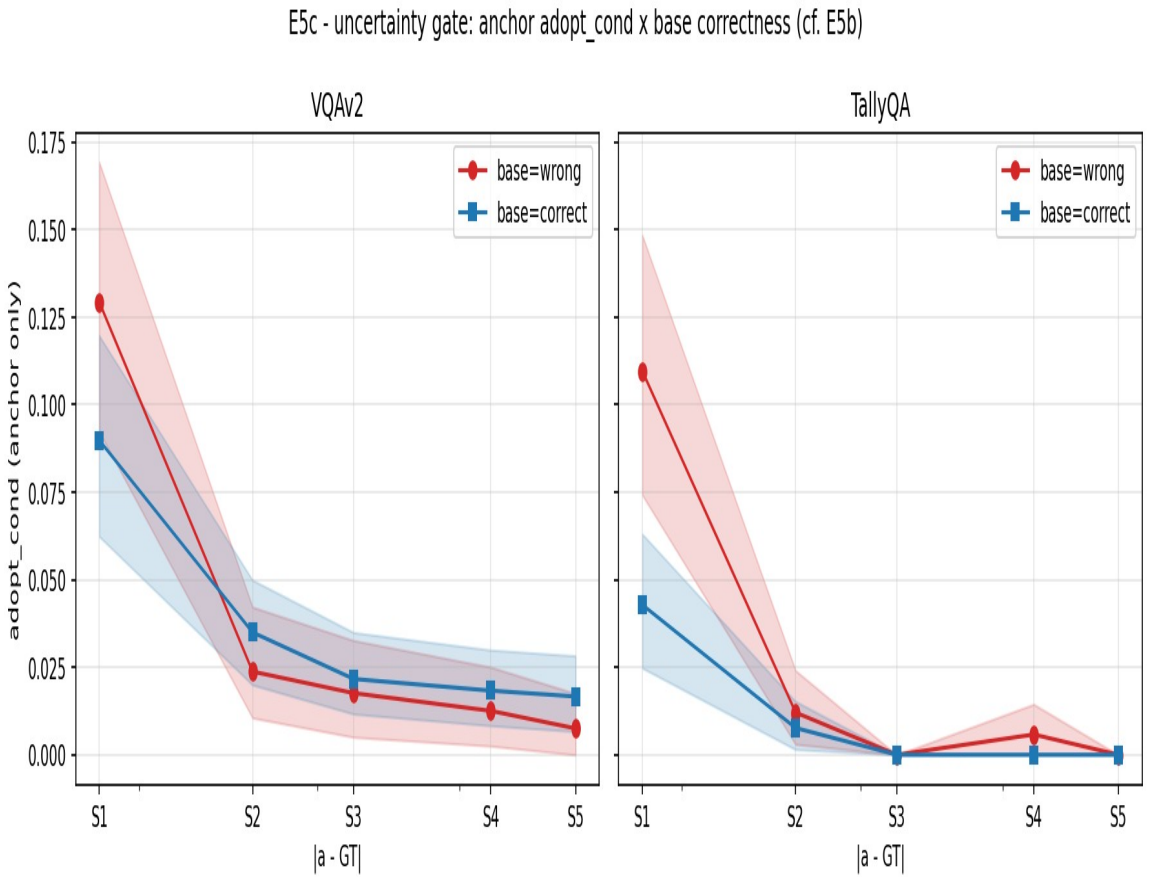

디지트 픽셀만 가렸을 뿐 배경은 동일 → adopt 큰 폭 감소 . background 자체는 generic distractor 정도의 영향만 .

Direction-follow 는 distance-invariant

anchor 와 masked 가 거의 동일 — generic 2-image distraction artifact

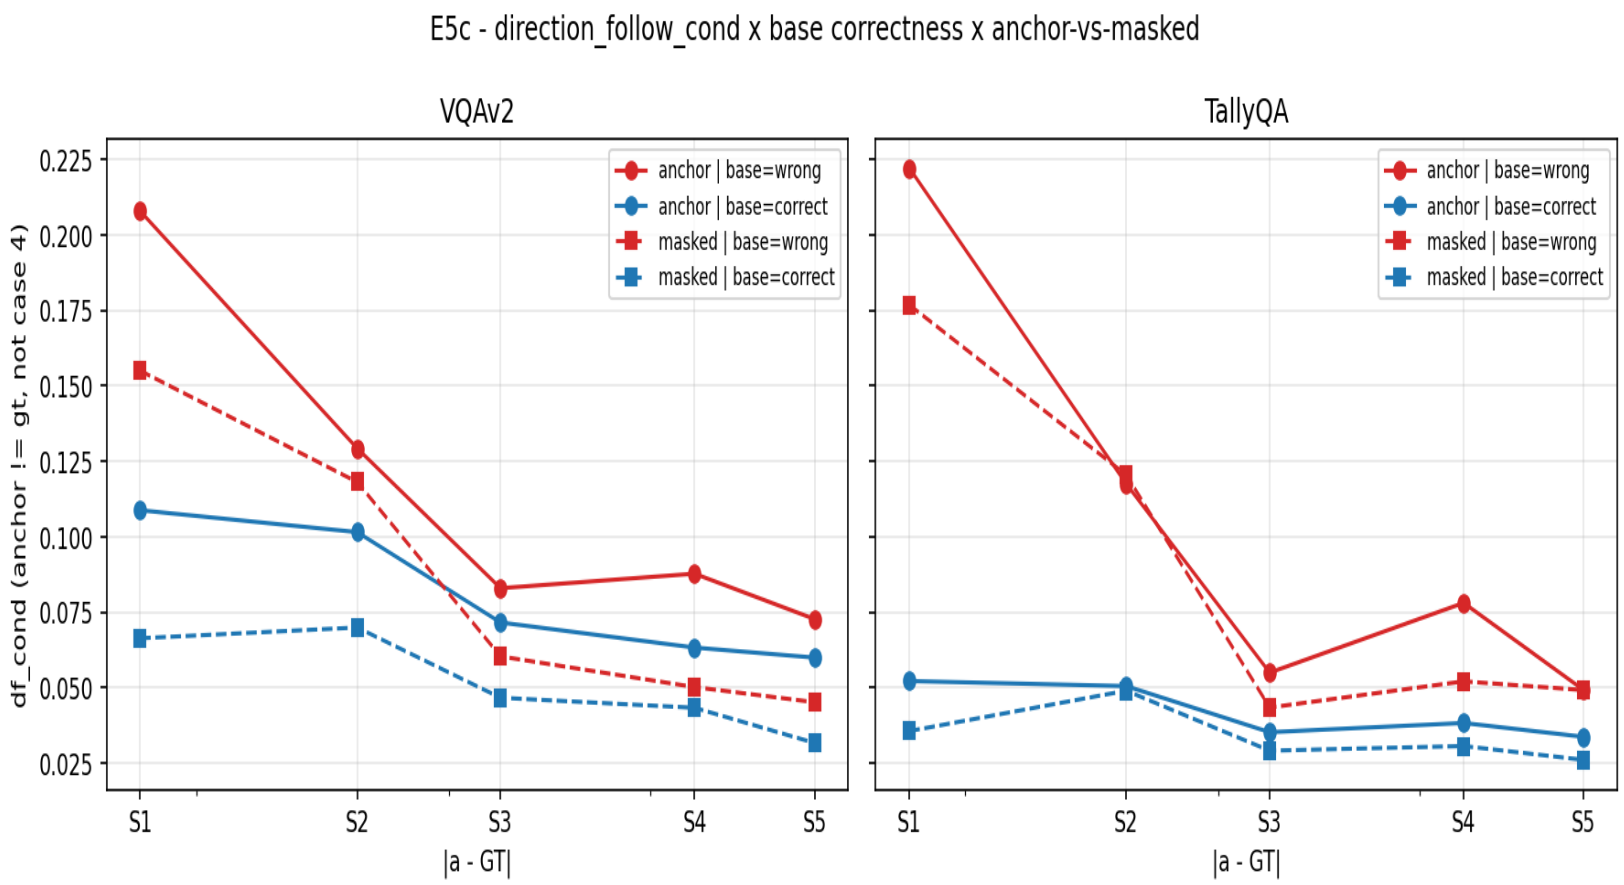

key 관찰

df_cond 는 S1~S5 거의 동일 (S1=0.36, S5=0.37)

anchor 와 masked 의 df_cond 도 거의 일치 (gap ≤ 0.005)

→ 'sign-based 방향 일치 ' 는 **두 번째 이미지가 있다는 사실 자체**에서 비롯된 generic perturbation.

정작 디지트 effect 는 adopt 에 집중 .

Per-dataset cutoff 검증 (E5d)

ChartQA: S1-only relative · MathVista: C3 FAIL (γ-α 로 이전)

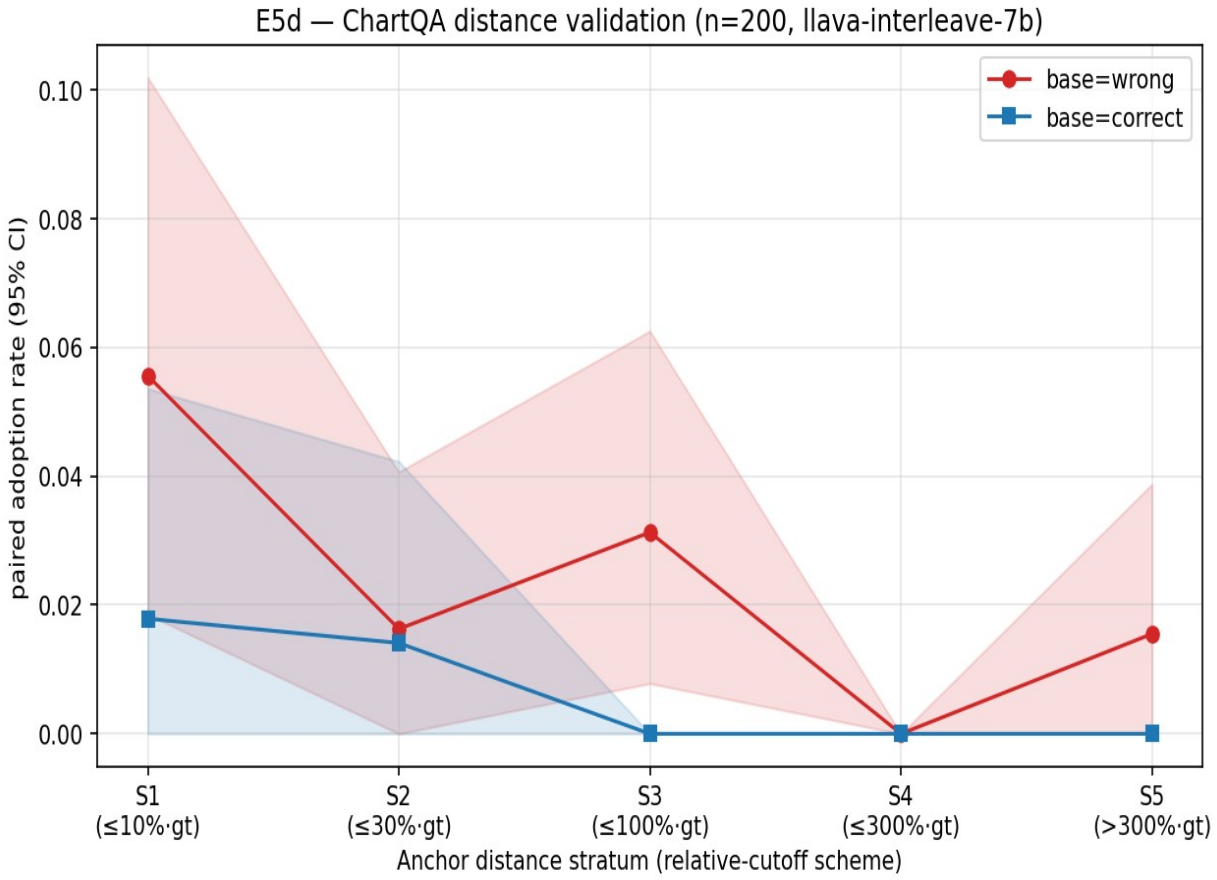

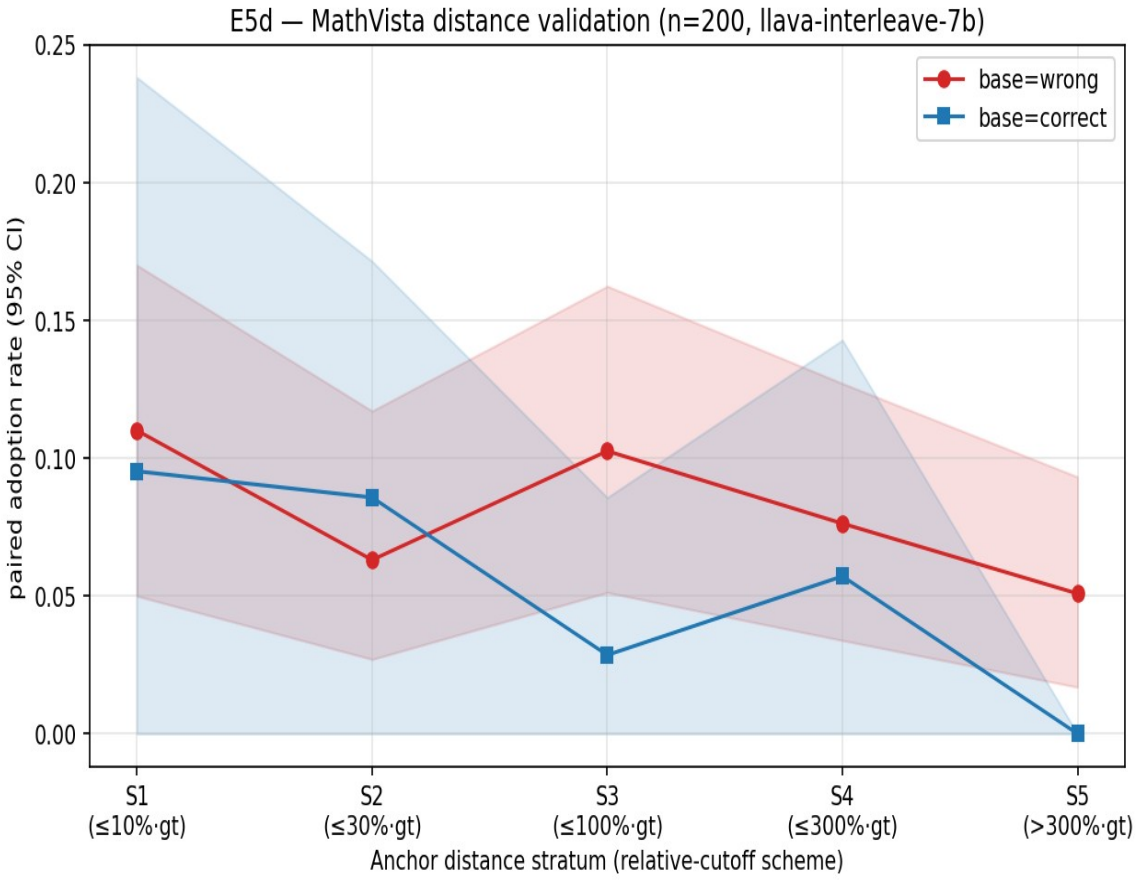

*ChartQA: [done] S1-only |a-gt| <= max(1, 0.1*gt) 채택 . MathVista E5d: [!] 모든 stratum diffuse -> C3 FAIL -> gamma-alpha 로 cross-model 재검증 .*

Cross-model × cross-dataset (E5e)

wrong-base S1 adopt_rate (M2) heatmap

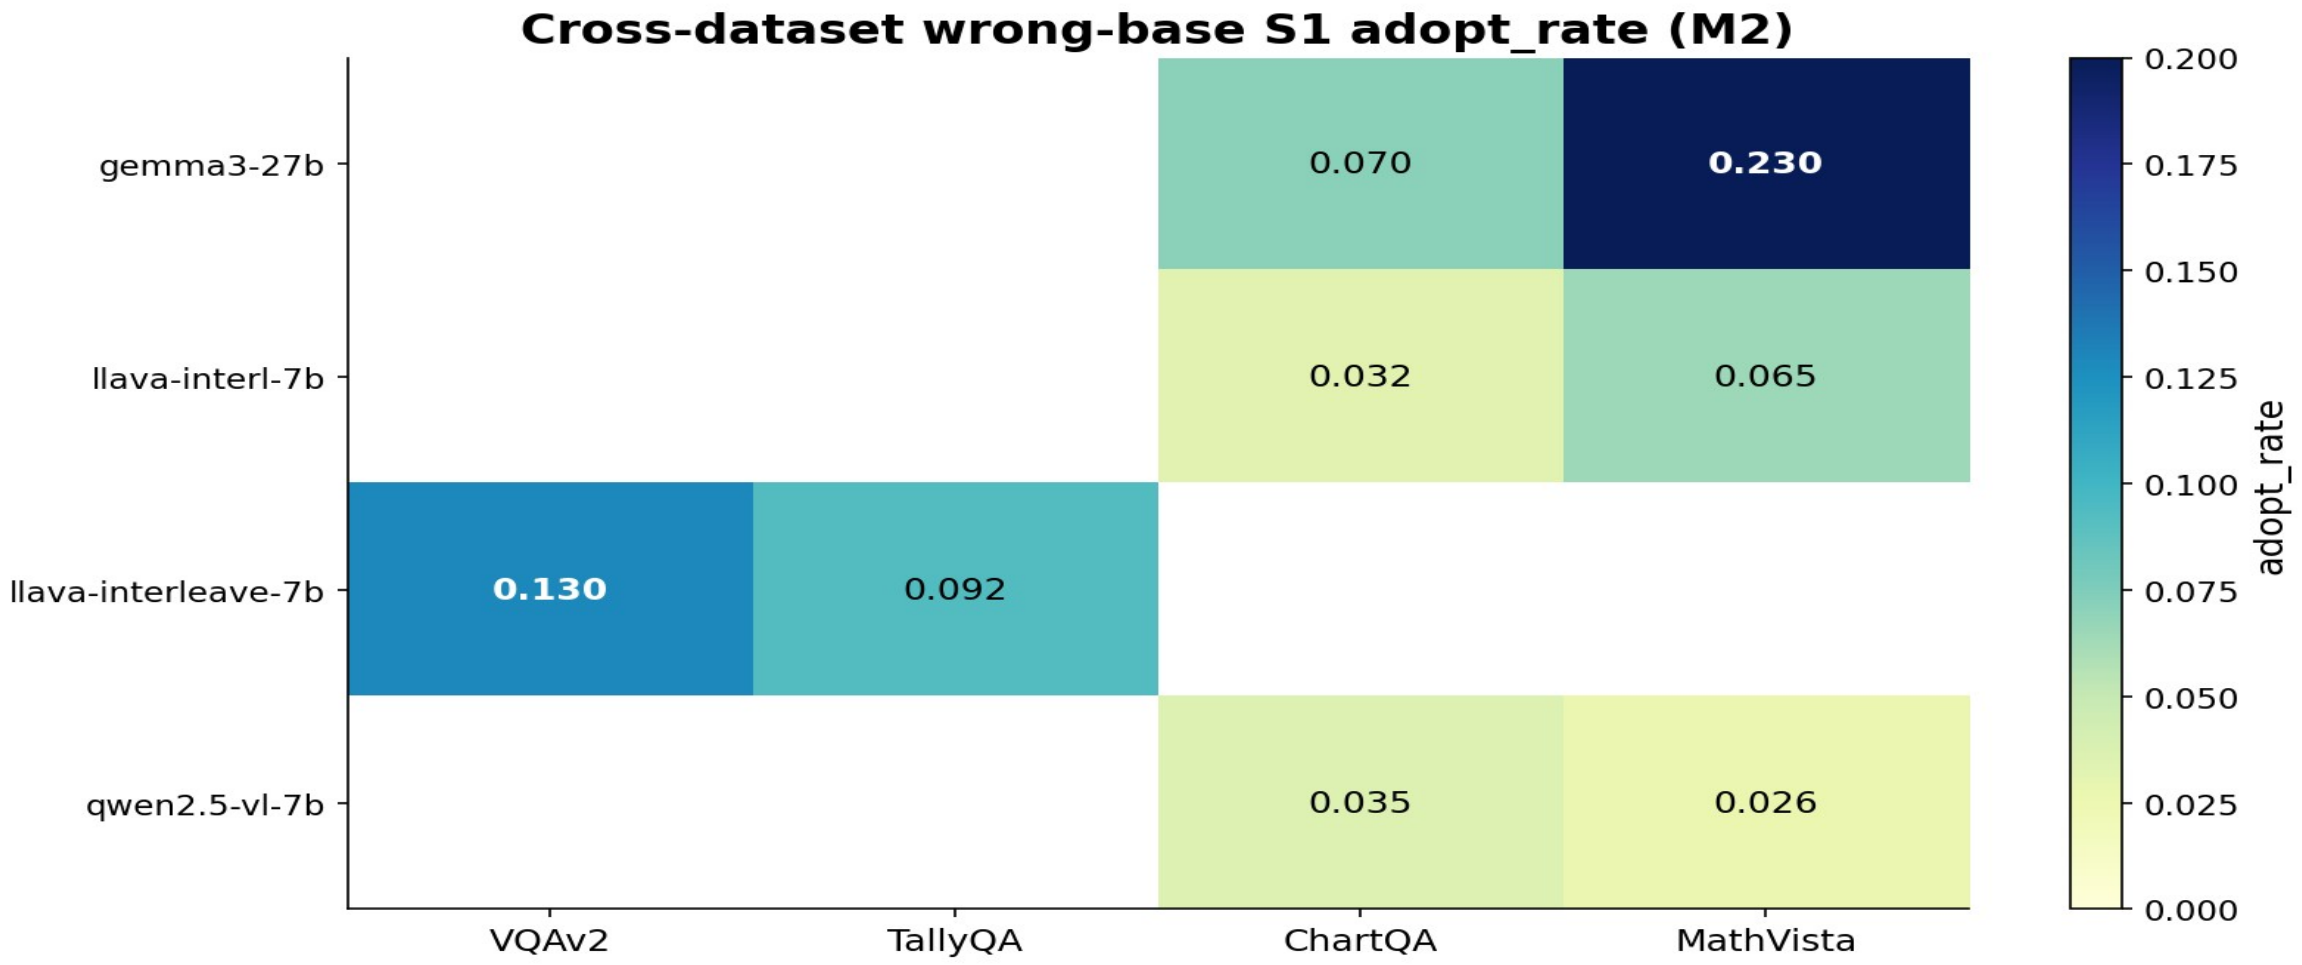

MathVista γ-α — categorical-replace regime

gemma3-27b adopt(a, wrong-base) = 0.194 — 본 프로그램에서 가장 큰 단일 셀

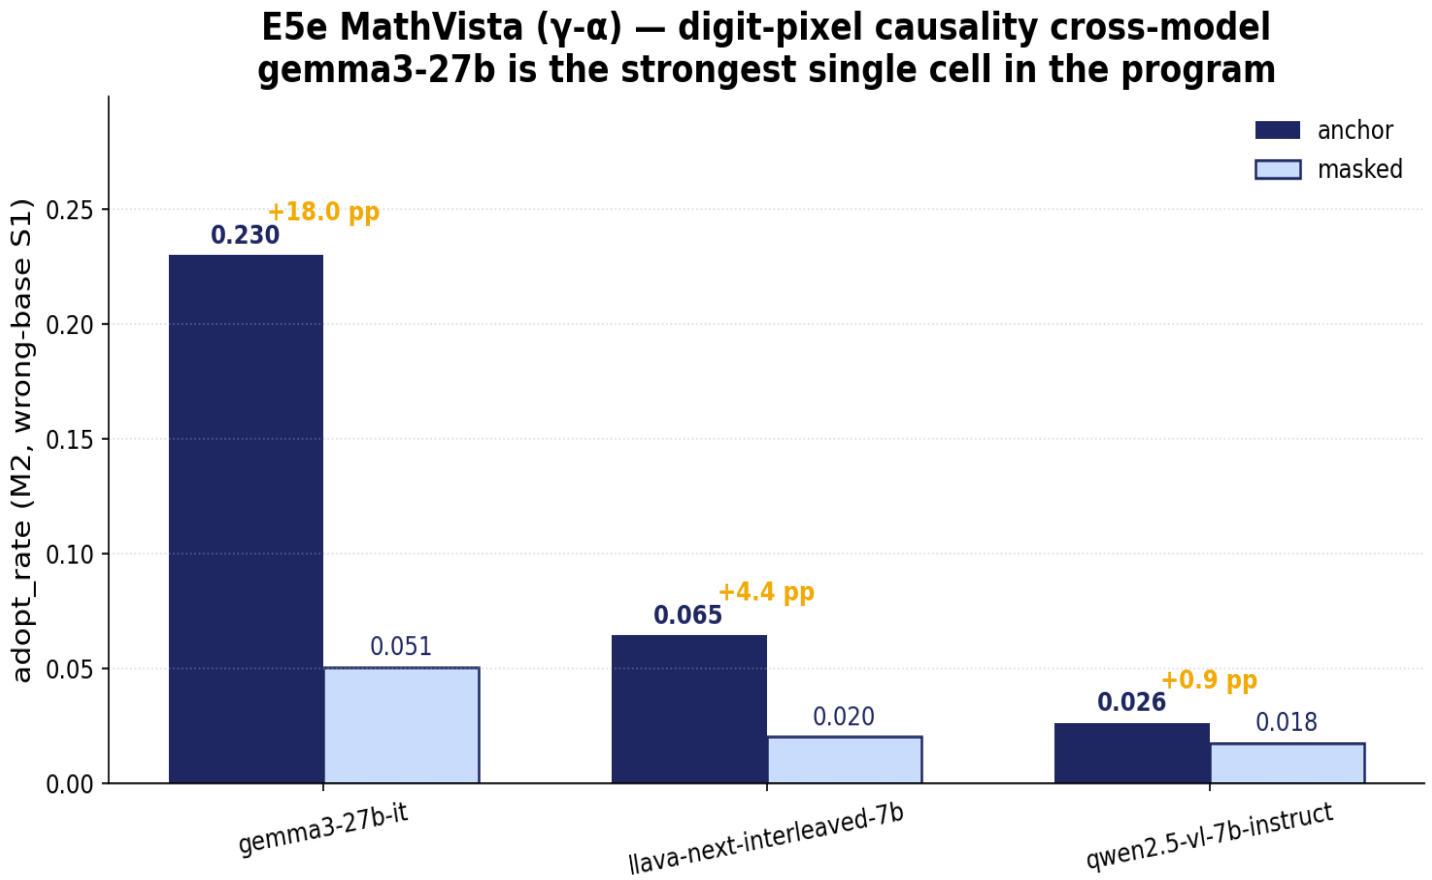

두 regime 의 발견

Graded-tilt (VQAv2/TallyQA/ChartQA)

anchor 가 search direction 을 비례적 이동 → df 큼, adopt 작음

Categorical-replace (MathVista)

anchor 가 base 답을 통째로 교체 → adopt 큼, df = 0

gemma3-27b 모델 + MathVista 조합에서 **adopt 0.194** 기록. 디지트 픽셀 인과 (a − m gap = **+15.2 pp**) 보존.

Confidence-modulated anchoring (L1, §6)

base prediction 의 entropy ↑ → anchor pull ↑ (graded)

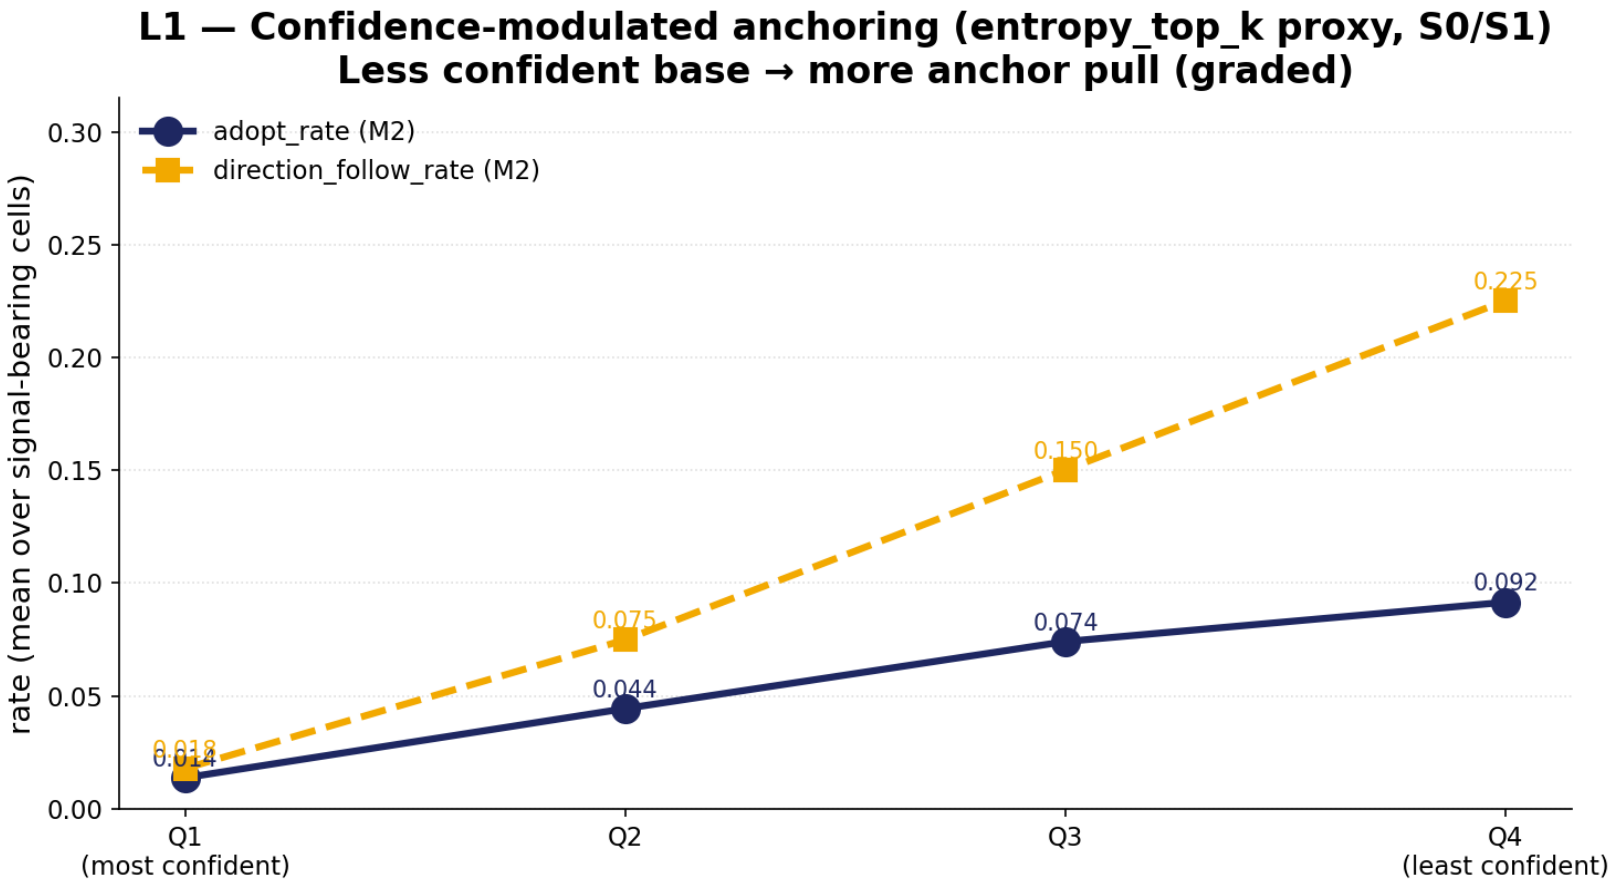

측정 방법

각 base inference 에서 답 토큰의 top-k entropy 계산
→ 모델 · 데이터셋 cell 마다 4 분위로 나눔

Q1 = 가장 confident 25%

Q4 = 가장 uncertain 25%

헤드라인

Q4 − Q1 mean df gap = **+0.128**
34 cells 중 18 개가 fully monotone
Q1<Q2<Q3<Q4

Q1 vs Q4 — worked example

E5c VQAv2 wrong-base S1, llava-interleave-7b, entropy_top_k 기준

quartile	어떤 records?	base 정답률	anchor adopt	direction-follow
Q1	가장 confident (entropy 낮음)	0.77 (대부분 정답)	0.077	0.040
Q2	upper-middle	0.50	0.090	0.080
Q3	lower-middle	0.27	0.110	0.090
Q4	가장 uncertain (entropy 높음)	0.07 (대부분 오답)	**0.147**	**0.113**
Δ (Q4−Q1)	—	−0.70	**+0.070 (+7.0 pp)**	**+0.074 (+7.4 pp)**

관계 : Phase A 의 wrong/correct binary 는 confidence quartile 의 **coarse projection**. Q1 mean exact_match=0.77 (정답 ~ correct), Q4 mean=0.07 (오답 ~ wrong).
그러나 quartile 은
confidently wrong / lucky correct 같은 예외 케이스를 더 정밀하게 분리한다 .

Attention mass 4-archetype (E1 + E1b)

6 모델 panel n=200 stratified — peak 위치 + δ + 메커니즘

Archetype	Encoder	Peak L	δ (anchor − neutral)	메커니즘 (budget decomposition)
SigLIP-Gemma early	SigLIP-So (gemma4-e4b)	L5 / 42 (12% depth)	+0.050	text-stealing (δ_text −0.038)
Mid-stack cluster	CLIP-ViT (llava-1.5)	L16 / 32	+0.019	text-stealing
Mid-stack cluster	InternViT (internvl3-8b)	L14 / 28	+0.019	text-stealing
Mid-stack cluster	ConvNeXt (convllava-7b)	L16 / 32	+0.022	text-stealing (H3 falsified)
Qwen-ViT late	Qwen-ViT (qwen2.5-vl-7b)	L22 / 28 (82%)	+0.015	target-stealing (anchor takes from target image)
FastVLM late	FastViT (fastvlm-7b)	L22	+0.047	text-stealing, A7 gap +0.086 (n=75)

H3 ("ConvNeXt < ViT") falsified — 3 개 다른 encoder 가 같은 mid-stack text-stealing profile.
→ "post-projection LLM stack depth" 가 axis (H6: 2-axis decomposition).

Causal ablation (E1d)

single-layer null · stack-wide breaks fluency · upper-half mitigation locus

Ablation 모드	Δ direction_follow (6 모델)	Fluency 영향	Use case
ablate_layer0	[−0.027, +0.005] — null on 6/6	clean	layer-0 control: 단일 레이어 효과 없음
ablate_peak (E1b 피크)	[−0.032, +0.020] — null on 6/6	clean	multi-layer redundancy 입증
ablate_lower_half	varies by archetype	clean → moderate	아키텍처별 효과 다름
ablate_upper_half	**[−0.115, −0.055] on 6/6**	**clean on 4/6 (mid-stack + Qwen)**	**[selected] E4 prototype locus**
ablate_all (stack-wide)	[−0.22, −0.11] universal	breaks on 3/6 (mean-dist 4–6×)	upper bound only

핵심: anchor 효과는 stack 전반에 redundantly encoded — single-layer 차단은 무의미. upper-half multi-layer 차단만이 architecture-blind mitigation locus.

Mitigation — "free lunch" (E4)

mid-stack cluster 3 모델 Phase 2 full validation: df ↓ · em ↑ · acc invariant

Model	s* (chosen strength)	Δ direction_follow	Δ exact_match	Δ accuracy_vqa(b)
llava-1.5-7b	−3.0	**0.258 → 0.212 (−17.7 % rel)**	**0.334 → 0.342 (+0.77 pp)**	invariant
convllava-7b	−2.0	**0.228 → 0.204 (−10.6 %)**	**0.352 → 0.365 (+1.30 pp)**	invariant
internvl3-8b	−0.5	**0.103 → 0.097 (−5.8 %)**	**0.590 → 0.595 (+0.49 pp)**	invariant

"Free lunch" 의미

df ↓ 함과 동시에 **em 이 오히려 상승** (anchor 에 끌렸던 wrong 답을 회복) → mitigation 으로 **정확도 손실 없음** .
base condition (no anchor) 의 acc 는
완전히 invariant — anchor-condition-specific hook (single-image inference 에 영향 0).

Future Work (§8)

VLM/LLM architectural diff 가 가장 priority 높음

VLM vs LLM architectural diff (preferred)

VLM 의 anchor pull 은 vision encoder → projection → LLM stack 의 mid-stack 에서 일어남 (E1b). LLM 에 anchor 를 text 로 줬을 때 어느 layer 분포에서 통합되는가? Layer-wise integration profile 비교로 architectural diff 입증.

Image vs text anchor 비교

anchor 를 image 로 줬을 때 vs. 동일 anchor value 를 텍스트로 줬을 때 effect 차이. cross-modal vs text-only LLM anchoring 정량 비교.

Reasoning-mode VLM (γ-β)

Qwen3-VL thinking 모드 활성화 + MathVista. reasoning chain 안에서 anchor 가 amplify/suppress 되는가? VLMBias 의 "reasoning models can be more biased" 를 cross-check.

Conclusion

Cross-modal numerical anchoring in VLMs is
uncertainty-modulated graded pull,
concentrating on a digit-pixel cue,
and mitigated by an encoder-blind upper-half locus —
without sacrificing accuracy.

01

Behavioural

wrong > correct on direction-follow +6.9–19.6 pp · L1 confidence quartile Q4-Q1 +0.128

02

Causal

anchor − masked gap 0.5–15 pp on wrong-base S1 across 4 datasets · digit-pixel 는 effect 의 인과

03

Mechanistic

4 archetypes 의 attention peak · upper-half ablation −5.5 to −11.5 pp on 6/6 architecture-blind

04

Mitigation

mid-stack cluster 3-model: df −5.8 to −17.7 % rel · em +0.5 to +1.3 pp · acc invariant — "free lunch"